

맵 리듀스를 부분적으로 대체한다.

스파크는 실행 엔진으로 맵 리듀스를 사용하지 않는다 . 대신 스파크는 클러스트 기반으로 작업을 실행하는 자체 분산 런타임 엔진

잡 사이의 대용량 작업 데이터셋을 메모리상에 유지 인메모리이기에 맵 리듀스 워크플로에 비해 10배 이상 빠르다. 이득을 얻는 에플리케이션 상황

- 반복적 알고리즘 (종료 조건을 만족할 떄까지 데이터셋에 함수를 반복 적용)
- 대화형 분석 (사용자가 데이터셋에 일련의 대화식 커리 생성)

인메모리 캐싱을 사용하지 않더라도 , DAG 엔진 , 사용자 경험 제공 DAG 엔진 : 연산자 중심의 파이프라인을 처리 → 사용자를 위한 단일잡으로 변환 조인과 같은 다양한 일반적인 데이터 처리 작업 수행 , 풍부한 API

지원 언어: 스칼라, JAVA, 파이썬 등등

read-eval-print loop(REPL) 커맨드 창 이용해서 코드 작성하는 거 말하는 듯

스파크 include (MLlib,GraphX,Spart Streaming, Spark Sql)

spark-shell (REPL 실행 명령어)
val lines = sc.textFile("input/ncdc/micro-tab/sample.txt)
↑ 예시에 불과

lines 변수는 탄력적인 분산 테이터셋(RDD)를 참조

스파크 1

다수의 머신에 분할되어 저장된 읽기 전용 컬렉션 RDD(읽기전용) → ETL → 목표 RDD 집합으로 변형, 영구정 저장소에 저장

val records = lines.map(_.split("\t"))

위 lines에서 읽어온 데이터셋을 한줄 씩 변환, 한 줄은 또 \t로 분할되어짐

val filtered = records.filter(rec \Rightarrow (rec(1) = "9999") && rec(2).mathes("[01459]"))) 9999로 표기된 기록 제거,

코드 보니간 파이썬으로 하는게 더 나을듯?

<생략>

maxTemps.saveAsTextFile("output")으로 저장
ex) output/part-* 양식으로 지정한 디렉터리 밑에 결과 파일들이 생성됨

스파크는 맵 리듀스와 유사하게 잡이라는 개념이 있다.

but, 하나의 맵과 하나의 리듀스로 구성된 단일 맵리듀스의 잡과 달리 스파크의 잡은 임의의 방향성 비순환 그래프(DAG)인 stage로 구성된다.

스테이지는 실행될때 다수의 TASK로 분할 \rightarrow 각 태스크는 mapredue의 태스크와 같이 클러스터에 분산된 RDD 파티션에서 병렬로 실행된다.

잡은 항상 RDD 및 공유변수를 제공하는 SparkContext내에서 실행된다.

하나의 에플리케이션은 여러개의 잡으로 구성될 수 있고 , 동일 에플리케이션에서 수행된 이전잡에서 캐싱된 RDD에 접근할 수 있는 메커니즘을 제공한다 . ?

그래서 RDD는 뭐지? RDD를 만드는 방법은 세가지

- 객체의 인메모리 컬렉션으로 생성
- HDFS와 같은 기존 외부 저장소의 데이터셋을 사용
- 기존의 RDD를 변환

우리는 2번을 쓰던지, 외부 데이터를 받아와 인모메리 컬렉션으로 변환해 쓰던지 스파크는 내부적으로 파일을 읽을 떄, 구버전 맵리듀스 API의 TextInputFormat을 이용, 파 일을 스플릿하는 방식은 하둡과 동일

RDD에서 트랜스포메이션과 액션이라는 두종류를 통해 새로운 RDD 생성

val text = sc.textFile(inputPath)

val lower : RDD[String] = text.map(_.toLowerCase())

lower.foreach(println(_))

map 은 트렌스포메이션

map에 정의된 함수는 액션이 foreach를 만나기 전까지 실제로 호출되지 않는다.

스파크에서는 풍부한 연산자 집합을 제공한다.

근데 mapreduce의 map,reduce 를 구현할려하면 메소드에 주의하라고 한다.

map

flatMap

집계 트랜스포메이션

reduceByKey

foldByKey

aggregateByKey

1 13

1 14

1 15

2 16

2 20

tuples.reduceByKey((a,b) ⇒ Math.min(a,b)).foreach(println(_)) 을 하면 1,2 키 중 가장 작은 값 출력

맵 리듀스는 다른 계산을 수행하기 위해서는 입력 데이터셋을 디스크에서 다시 불러와야한 다.

따라서 I/O 발생 , 스파크는 여러 머신에 있는 메모리에 데이터셋을 분산하여 캐싱할 수 있어 빠르게 처리가능 ,cache()를 호출해야함

메모리 작다고 RDD 파티션 저장 수행을 실패하지는 않음, 하지만 연산 과정중 실패하면 다시 계산을 수행해야할 경우 휘발되니깐 다시 해야함, 중간 중간 저장하는 persist메서드를 사용가능

직렬화

공유변수

브로드 캐스트 변수

어큐뮬레이터

YARN 에서 스파크 실행

YARN 클러스터 모드: 운녕에 유리,

YARN 클라이언트 모드: 대화형 컴포넌트 필요, 디버깅 용이

요약 : map reduce 비슷하게 사용가능, 문법이다름 , 더 빠름(특정상황 ex 작을 때) , 연속적 처리가 필요할 때(map reduce는 한 시퀀스로 끝나니깐)

스파크